


Curso de Verão de Bioinformática 2026 – UFMG

Introdução à Análises Ecológicas no R

João Pedro Machado Rodrigues





Quem sou eu

Ciências Biológicas - Licenciatura

UFMG | 2018 – 2024

Mestrado – PPG ECMVS

UFMG | 2025 – presente



J4	=VLOOKUP(I4;\$A\$2:\$B\$12;2;FALSE())																																																
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S																														
1	Dado	Estrela			Dados da casa	Valor			Recursos																																								
2	2	1		1º	2	1			Dados		Valor	Dados		Valor	Dados		Valor	Dados		Valor																													
3	3	2		2º	3	2			9	4	6	5	4	3	2	1	10	3																															
4	4	3		3º	2	1			3	2	10	3	6	5	4	3	8	5																															
5	5	4				4	Total		11	2	5	4	12	1	5	4	3	2																															
6	6	5							8	5			9	4	11	2																																	
7	8	5			Dados da casa	Valor			13		12		13		10		10																																
8	9	4		1º	2	1																																											
9	10	3		2º	3	2																																											
10	11	2		3º	0	0																																											
11	12	1				3	Total																																										
12	0	0																																															
13																																																	
14		Knight	VP	Estrada	Recursos	Monopólio																																											
15	Jogadas	0	0	0	0	0																																											
16	Restantes	14	5	2	2	2																																											
17		+1	+1	+1	+1	+1																																											
18																																																	
19		Reset	Reset	Reset	Reset	Reset																																											
20																																																	
21		Reset All																																															
22																																																	
23																																																	
24																																																	
25																																																	
26																																																	




Objetivos do curso

- Fornecer uma perspectiva humana de como utilizar o R
- Como pensar em análises estatísticas sem ser um estatístico
- Compartilhar materiais e outros recursos úteis

A Primer of Ecological Statistics

Second Edition

NEW CHAPTERS
Estimating Species Diversity
Estimating Species Abundance



NICHOLAS J. GOTELLI • AARON M. ELLISON

ANÁLISES ECOLÓGICAS NO R

O melhor caminho entre questões ecológicas e os métodos estatísticos mais robustos para testá-las

Fernando Rodrigues da Silva
Thiago Gonçalves-Souza
Gustavo Brant Paterno
Diogo Borges Provete
Maurício Humberto Vancine

NUPEEA

O'REILLY

Second Edition

R for Data Science

Import, Tidy, Transform, Visualize, and Model Data




Hadley Wickham,
Mine Çetinkaya-Rundel
& Garrett Grolemund

Qual nosso objetivo ao fazer análises estatísticas?

- Descrever padrões da natureza
- Entender fenômenos observáveis
- Testar hipóteses sobre fenômenos
- Fazer ciência
 - “Método científico”

Método indutivo



Francis Bacon
(1561–1626)

Dedução vs *Indução*

Geral > Específico


1. Todos os metais se expandem expostos ao calor
2. O ferro é um metal
3. O ferro se expande exposto ao calor

Específico > Geral


1. O metal X se expande exposto ao calor
2. Metal Y se expande ao calor
3. Todos os metais se expandem expostos ao calor

Método hipotético-dedutivo



- Baseado na premissa da falsificação
- Uma hipótese nunca pode ser confirmada



Karl Popper
(1902–1994)





Teoria dos paradigmas



Thomas Kuhn
(1922–1996)

Paul Feyerabend

- Anarquista epistemológico
- Impossível (e danoso) existir um método científico
- “Anything goes”




Perguntas básicas para uma pesquisa científica

1. Qual é a principal teoria ou raciocínio lógico do seu estudo?
2. Qual é a questão principal do seu estudo?
3. Qual é a sua hipótese? Quais são suas previsões?
4. Qual é a unidade amostral, variável independente e dependente do seu trabalho? Existe alguma covariável?
5. Qual é o grupo controle?

Método hipotético-dedutivo

- Estabelecer hipóteses
- Articular previsões
- Desenhar e executar experimentos

Coletar, organizar e resumir os dados
Testes estatísticos




Capítulo 1 – Uma introdução à probabilidade

Estatística

Comum à todas as ciências

Baseada na incerteza

Fundamentada na
probabilidade




$$P(H) = 0.50 \text{ (ou } 50\%) \quad P(6) = \frac{1}{6} \text{ (ou } \approx 0.16)$$

Estatística

Comum à todas as ciências

Baseada na incerteza

Fundamentada na
probabilidade



$$P(H) = \frac{\text{n}^\circ \text{ de resultados favoráveis}}{\text{n}^\circ \text{ de resultados possíveis}}$$

Probabilidade de um evento simples

Evento: Cara (H)

Resultados: Cara (H) ou Coroa (T);

Espaço amostral: $(\Omega) = n(H) + n(T)$



$$P(H) = 0.50 \text{ (ou 50\%)}$$

Fórmula da probabilidade de um evento simples

$$P(H) = \frac{n(H)}{n(\Omega)} \quad 0.0 \leq P \leq 1.0$$

$P(H)$ = prob. do evento H ocorrer.

$n(A)$ = n° de vezes que ocorre A

$n(\Omega)$ = espaço amostral = $n(H) + n(T)$

Eventos complexos

A soma (união) de dois eventos
independentes

Eventos compartilhados

A interseccção (multiplicação) de dois
eventos dependentes



Euro coin accused of unfair flipping

By [Debora Mackenzie](#)

📅 4 January 2002



The introduction of the Euro, the largest currency switch in history, has proceeded with few problems – until now. Polish statisticians say the one Euro coin, at least in Belgium, does not have an equal chance of landing “heads” or “tails”. They allege that, when spun on a smooth surface, the coin comes up heads more often.

The observation is not to be taken lightly on a sports-mad continent where important decisions can turn on the flip of a coin. But the accusation of bias has been countered by statistical analysis from, of all places, Euro-sceptic Britain. The UK is one of only three EU countries that have not adopted the common currency.

<https://www.newscientist.com/article/dn1748-euro-coin-accused-of-unfair-flipping/>



Tomasz Gliszczynski Wacław
Zawadowski

$n = 250$

56% das vezes caiu cara ($n=140$)

A moeda é enviesada?

Eu não vim aqui aprender estatística, eu só quero saber se minha análise é significativa ou não

Medindo probabilidade

Evento: Visita

Resultados: Fuga (F) ou Captura (C);


Espaço amostral: $(\Omega) = (F) + (C)$

Esforço amostral: 52 amostras,
1000 replicatas por amostras




Como medir a probabilidade de sucesso da planta?


Amostragem



Id	Semana	Capturas
1	1	7
2	2	13
3	3	15
4	4	14
5	5	11
6	6	14
7	7	11
8	8	6
9	9	7
10	10	10




Distribuição normal




Probabilidade de distribuição

padrões (na frequência) que eventos podem assumir

Distribuição binomial




Distribuição de Poisson



Distribuição binomial

Contagem binária de
trials (ensaios)








Distribuição de Poisson


Usada quando as ocorrências de um evento são raras (valor mais comum é 0)

- n grande e p pequeno


Conta eventos de interesse que ocorrem em uma amostragem, quando não se pode contar todos os trials

λ = valor médio do numero de ocorrências em cada amostragem






$\neq$




“[W]e now know that what we term natural laws are merely statistical truths and thus must necessarily allow for exceptions. ...[W]e need the laboratory with its incisive restrictions in order to demonstrate the invariable validity of natural law. If we leave things to nature, we see a very different picture: every process is partially or totally interfered with by chance, so much so that under natural circumstances a course of events absolutely conforming to specific laws is almost an exception.”



CARL JUNG, Foreword to The I Ching or Book of Changes. Third Edition, 1950, translated by R. Wilhelm and C. F. Baynes. Bollingen Series XIX, Princeton University Press.




$\neq$




Lei dos números grandes





$\neq$




Variável aleatória:

Função que atribui o valor provável para cada resultado possível dentro de de um espaço amostral


Discretas



Contínuas



Variável aleatória:



Valor esperado E e variância σ^2

para uma variável aleatória (X)

$$E(X)$$

*O valor típico de uma
variável aleatória*

$$\sigma^2(X)$$

O quão longe eses valores
diferem do valor esperado

$$P(H) = \frac{n(H)}{n(\Omega)}$$

Valor esperado E e variância σ^2

para uma variável aleatória (X)

$$E(X)$$

O valor típico de uma variável aleatória

$$= a_1p_1 + \dots + a_np_n$$

$$= \sum_{i=1}^n a_i p_i$$

$$\sigma^2(X)$$

O quão longe eses valores diferem do valor esperado

$$= E[X - E(X)]^2$$

$$= \sum_{i=1}^n p_i \left(a_i - \sum_{i=1}^n a_i p_i \right)^2$$

By removing the exponent from Equation 9.6 and expanding the squared term, we can re-write it as

$$SS_Y = \sum_{i=1}^n (Y_i - \bar{Y})(Y_i - \bar{Y}) \quad (9.8)$$

Now let's consider the situation with two variables X and Y . Instead of the sum of squares for one variable, we can define the **sum of cross products** (SS_{XY}) as

$$SS_{XY} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) \quad (9.9)$$

and the **sample covariance** (s_{xy}) as

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) \quad (9.10)$$

Population vs. Sample

Population
Parameters

Sample
Statistics

μ = Mean = $\bar{x}$

p = Proportion = $\hat{p}$

σ = Std Dev. = s

N = Size = n

ρ = Correlation
Coefficient = r



Graus de liberdade

Número de informações independentes que temos no nosso conjunto de dados para estimar o parâmetros estatísticos.

Em um conjunto de dados $n=1$, não há observações independentes.

Distribuições estatísticas discretas

Distribution	Probability value	$E(X)$	$\sigma^2(X)$	Comments	Ecological example
Bernoulli	$P(X) = p$	p	$p(1 - p)$	Use for dichotomous outcomes	To reproduce or not, that is the question
Binomial	$P(X) = \binom{n}{X} p^X (1 - p)^{n-X}$	np	$np(1 - p)$	Use for number of successes in n independent trials	Presence or absence of species
Poisson	$P(x) = \frac{\lambda^x}{x!} e^{-\lambda}$	λ	λ	Use for independent rare events where λ is the rate at which events occur in time or space	Distribution of rare species across a landscape

Distribuições estatísticas contínuas

Distribution	Probability value	E(X)	$\sigma^2(X)$	Comments	Ecological example
Uniform	$P(a < X < b) = 1.0$	$\frac{b+a}{2}$	$\frac{(b-a)^2}{12}$	Use for equiprobable outcomes over interval $[a,b]$	Even distribution of resources
Normal	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}$	μ	σ^2	Generates a symmetric “bell curve” for continuous data	Distribution of tibial spine lengths or other continuous size variables
Log-normal	$\frac{1}{\sigma X\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{\ln(X)-\mu}{\sigma}\right)^2}$	$e^{\frac{2\mu+\sigma^2}{2}}$	$\left[e^{\frac{\mu+\sigma^2}{2}}\right]^2 \times [e^{\sigma^2}-1]$	Log-transformed data of right-skewed data are often fit by a normal distribution	Distribution of species abundance classes
Exponential	$P(X) = \beta e^{-\beta X}$	$1/\beta$	$1/\beta^2$	Continuous distribution analog of Poisson	Seed dispersal distance

Revisando...

Probabilidades de distribuições (de frequências) são padrões comumente encontrados na natureza, que podem ser descritos por ...

variáveis aleatórias são funções que atribuem um *valor numérico para cada resultado possível* de um experimento

Variáveis aleatórias possuem **valores e variâncias esperados** que podem ser calculados

Tipos de variáveis

Variável resposta/dependente:

O efeito de uma causa hipotética.

Variável preditora/independente:

A causadora desse efeito.

Quatro classes de testes estatísticos

Variável dependente	Variável independente	
	Contínua	Categórica
Contínua	Regressão	Anova
Categoria	Regressão logística	Tabular

1. Variáveis quantitativas ou contínuas

1.1. Variáveis numéricas

Abundância
Massa corporal
Quantidade de lenha
Propensão para caçar

1.2. Variáveis discretas

Idade
Riqueza de espécies

1.3. Variáveis binários

Composição de espécies (0 para ausência, 1 para presença)
Sobrevivência (0 para morto, 1 para vivo)

1.4. Variáveis circulares (tempo)

Tempo de floração e frutificação
Abundância mensal

2. Variáveis categóricas ou qualitativas

2.1. Variáveis nominais (elas não expressam magnitude)

Tratamento (A, B, e Controle)
Técnica de pesca (X, Y, e Z)

2.2. Variáveis ordinais (ordem expressa magnitude)

Classe de tamanho (pequeno, médio ou grande)
Grau de urbanização (rural, peri-urbano, urbano)
Estimativa de abundância (zero, poucos, or muitos)

Síntese estatística

Tendência central

- Médias
- Medianas
- Modas

Dispersão

- Desvio padrão
- Variância
- Erro padrão

Intervalo de confiança

- O valor real do parâmetro está dentro do intervalo de confiança em 95 das 100 amostras realizadas
- Mostra o quão confiável é o método.

Significância estatística e Valores de P

- Todo teste produz dois resultados:
 - Estatística do teste
 - Valor de P (valor de probabilidade)
- Probabilidade que a diferença medida é explicada no caso da H_0 ser verdadeira

Hipótese nula vs Hipótese alternativa

$$H_0$$

A diferença entre tratamentos não é maior do que o esperaríamos que fosse se causada por fatores aleatórios

Não há mecanismo por trás


$$P > 0,05$$

$$\neg H_0$$

A diferença entre tratamentos é maior do que o esperado se fosse causada por fatores aleatórios.

Há algum mecanismo por trás que tentamos elucidar .

$$P \leq 0,05$$



Valor de P

$$P(\text{dados} | H_0)$$

O que determina o valor de P? ↓

- ↑ Tamanho amostral (n)
- ↑ Diferença da média entre tratamentos ($\bar{Y}_i - \bar{Y}_j$)
- ↓ Variação entre amostras do mesmo grupo (s^2)

Erros estatísticos

	Manter H_0	Rejeitar H_0
H_0 verdadeira	Decisão correta	Erro tipo I (α)
H_0 falsa	Erro tipo II (β)	Decisão correta



Tipos de transformações de dados

- Transformação logarítmica – Usada para dados contáveis
- Transformação recíproca – Usada para dados de proporção/taxas


Cap 5 -

Frameworks para
análise estatística

Frameworks para análise estatística



Estatística frequentista




Regressão

Premissas da regressão

- Amostras independentes
- Unidades amostrais aleatórias
- Distribuição normal dos resíduos
- Homogeneidade da variância
- Ampla e uniforme amostragem de valores de Y

Equação de uma reta


$$Y = \beta_0 + \beta_1 X$$




- β_0 : Intercept
 - $X = 0$
- β_1 : Slope
 - Inclinação

Regressão linear

$$Y = \beta_0 + \beta_1 X + \varepsilon_i$$



- β_0 : Intercept
 - $X = 0$
- β_1 : Slope
 - Inclinação
- ε_i : Erro



Quadrado residual = A diferença entre o valor de observado e o valor encontrado elevada ao quadrado para cada observação

Soma dos quadrados residuais RSS = A soma para todos os valores de Y

$$d_i^2 = (Y_i - \hat{Y}_i)^2$$


$$RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Regressão


Premissas da regressão

- Amostras independentes
- Unidades amostrais aleatórias
- Distribuição normal dos resíduos
- Homogeneidade da variância
- Ampla e uniforme amostragem de valores de Y


(A)




(B)



(A)



Y variable



ANOVA

Premissas da ANOVA

- Amostras independentes
- Unidades amostrais aleatórias
- Distribuição normal dos resíduos
- Homogeneidade da variância entre tratamentos
- Ampla e uniforme amostragem de valores de Y

ANOVA

Análise de Variância


- A comparação das médias entre tratamentos
- Divide a variância em dois componentes de variação:
 - Variação entre grupos
 - Variação dentro grupos

Tabela ANOVA para fator único lm()

TABLE 9.1 Complete ANOVA table for single factor linear regression

Source	Degrees of freedom (df)	Sum of squares (SS)	Mean square (MS)	Expected mean square	F-ratio	P-value
Regression	1	$SS_{reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$	$\frac{SS_{reg}}{1}$	$\sigma^2 + \beta_1^2 \sum_{i=1}^n X_i^2$	$\frac{SS_{reg} / 1}{RSS / (n - 2)}$	Tail of the F distribution with 1, $n - 2$ degrees of freedom
Residual	$n - 2$	$RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$	$\frac{RSS}{(n - 2)}$	σ^2		
Total	$n - 1$	$SS_Y = \sum_{i=1}^n (Y_i - \bar{Y})^2$	$\frac{SS_Y}{(n - 1)}$	σ_Y^2		

ANOVA um fator




ID number	Treatment	Replicate	Number of barnacle recruits
1	Granite	1	12
2	Slate	1	10
3	Cement	1	3
4	Granite	2	14
5	Slate	2	10
6	Cement	2	8
7	Granite	3	11
8	Slate	3	11
9	Cement	3	7
.	.	.	.
.	.	.	.
30	Cement	10	8

ANOVA


em blocos aleatorizados

Incorpora heterogeneidade ambiental
-Necessário independência entre tratamentos



Anova aninhada

Mais subamostras, ainda que não sejam independentes aumentam a precisão da estimativa da média -
Permite ver se há variação entre tratamentos e dentro de tratamento



Anova fatorial

Substrate treatment (<i>one-way layout</i>)		
Granite	Slate	Cement
 10	 10	 10

Predator treatment (<i>one-way layout</i>)			
Unmanipulated	Control	Predator exclusion	Predator inclusion
10	 10	 10	 10

(*Simultaneous predator and substrate treatments in a two-way layout*)

		Substrate treatment		
		Granite	Slate	Cement
Predator treatment	Unmanipulated	 10	 10	 10
	Control	 10	 10	 10
	Predator exclusion	 10	 10	 10
	Predator inclusion	 10	 10	 10

- 2+ fatores
- Cada tratamento é um fator, e cada categoria é um nível de tratamento
 - Cada nível de tratamento é combinado.
- Permite ver efeitos principais (isolados) e de interação entre fatores

Introdução ao R e ao RStudio



<https://www.r-project.org>

Linguagem de
programação



<https://posit.co/downloads/>

Integrated Development
Environment (IDE)

Introdução ao R e ao RStudio



<https://www.r-project.org>



<https://posit.co/downloads/>

Por que usá-los em Ecologia?

- Free Open Source Software (FOSS);
- Foco em análises estatísticas/gráficos;
- Flexível para usos diversos;
- Pacotes especializados;
- Amplamente utilizado para análises ecológicas

Figure 1: Annual usage proportion of R in scholarly articles across 40 ecology research journals from 2008 to 2023. Compilation based on 125 494 articles, with R^2 values of 0.99 ($P < 0.001$) for the period 2008–2017 and 0.98 ($P < 0.001$) for 2017–2023.


A comprehensive analysis of R's application in ecological research from 2008 to 2023


Meixiang Gao, Yanyan Ye, Ye Zheng, Jiangshan Lai 

Journal of Plant Ecology, Volume 18, Issue 1, February 2025, rtaf010,

<https://doi.org/10.1093/jpe/rtaf010>

Published: 16 January 2025 **Article history** ▼





Interface do RStudio

- Editor de scripts;
- Console;
- Ambiente de trabalho e;
- Painel de visualização.

Gerenciamento de pacotes

```
install.packages()
```

```
# Instalar versões específicas
```

```
remotes::install_version("pacote", version = "x.x.x")
```

```
# Instalar de repositórios específicos
```

```
install.packages("pacote", repo = "repo")
```

```
# Chamar o pacote para o environment
```


```
library()
```

```
# Caso o pacote não esteja disponível, olhar o arquivo dele no CRAN
```


```
# Alguns pacotes podem não estar distribuídos pelo CRAN, ex:
```

```
# BiocManager, github, etc
```

Gerenciamento de projetos e pacotes no R



rig: Gerenciar versões do R



<https://github.com/r-lib/rig>

Visualizar dados

#Visualização

##Ver um objeto (tipo clicar no environment)

View(df)

#Visão estruturada:

str(df)

#Ver um sumário:

summary(df)

#Ver a classe:

class(df)

#Ver as n(opcional) primeiras e últimas linhas de um df:

head(x, n)

tail(x , n)

Estruturas de dados no R

single type

multiple types

1D

Vector



`vector()`


List



`list()`

2D

Matrix



`matrix()`

Data frame




`data.frame()`

nD

single type

Array



`array()`

Tipos de dados no R

```
obj <- dados
```

```
typeof()
```

Objetos: Conjunto de dados nomeado e armazenado no R.

- **atomic vector:** um vetor de data simples
- **doubles:** números regulares.
 - Em geral, o R salva qualquer número como um double.
- **integers:** números sem componentes decimais.
- **characters:** pequenos pedaços de texto.
 - Cada elemento individual é uma string.
- **logicals:** Boolean, ou true ou false

Objetos

Atributos de objetos

- Nomes:
- Dimensões
- Classes
 - **Fator**

```
obj <- dados
```

```
attributes()
```

```
class() dim() names()
```

```
factor()
```

Notações úteis para usar com objetos



- **Índice:** Seleciona valores

```
dados[<l>, <c>]
```

```
dados[[<l>, <c>]]
```

- **Extrair colunas:** funciona para data frames e listas

```
df$coluna
```



The background of the slide is a dark blue field filled with numerous small, colorful hexagons and dots in various colors including red, orange, yellow, green, blue, and grey. These shapes are scattered across the entire background, creating a confetti-like effect.

Manipulação, organização e visualização de dados com o tidyverse



R packages for data science


The tidyverse is an opinionated **collection of R packages** designed for data science. All packages share an underlying design philosophy, grammar, and data structures.

Install the complete tidyverse with:

```
install.packages("tidyverse")
```

Tidy data

Organizar planilhas de maneira consistente entre pacotes



Each **variable** is in its own **column**


&



Each **observation**, or **case**, is in its own row



Access **variables** as **vectors**



Preserve **cases** in vectorized operations

Estrutura do Experimento: Cardumes vs. Predadores

Teoria: Efeito de Diluição / Confusão do Predador (Vantagem adaptativa da vida em grupo).

Hipótese: O tamanho do cardume altera a taxa de encontro/sucesso do predador.

Predição: Grupos maiores apresentarão menor taxa de aproximação por indivíduo do que grupos menores



Teste	T3	T5	T10	T15	T20
1	0.9	0.7	0.4	0.4	0.1
2	0.8	0.8	0.5	0.5	0.1
3	0.7	0.9	0.6	0.3	0.2
4	1.1	0.6	0.8	0.2	0.3
5	1.0	1.0	0.7	0.6	0.3



```
df2 <-
pivot_longer(
  data = df,
  # define as colunas a serem transformadas
  cols = c(T3,T5,T10,T15,T20),
  # define o nome da nova coluna a ser criada
  names_to = "tamanho_do_cardume",
  # define o nome da coluna dos valores
  values_to = "número_de_abordagens"
)
```

Teste	Tam.	Nº ab.
1	T3	0.9
1	T5	0.7
1	T10	0.4
1	T15	0.4
1	T20	0.1
2	T3	0.8
2	T5	0.8
2	T10	0.5
2	T15	0.5
2	T20	0.1
3	T3	0.7
3	T5	0.9
3	T10	0.6
3	T15	0.3
3	T20	0.2
4	T3	1.1

Organizando dados com tidyr



`pivot_longer()`

table4a

country	1999	2000
A	0.7K	2K
B	37K	80K
C	212K	213K



country	year	cases
A	1999	0.7K
B	1999	37K
C	1999	212K
A	2000	2K
B	2000	80K
C	2000	213K

`pivot_longer`(data, cols, names_to = "name", values_to = "value", values_drop_na = FALSE)

"Lengthen" data by collapsing several columns into two. Column names move to a new names_to column and values to a new values_to column.

```
pivot_longer(table4a, cols = 2:3, names_to = "year",  
              values_to = "cases")
```

`pivot_wider()`

table2

country	year	type	count
A	1999	cases	0.7K
A	1999	pop	19M
A	2000	cases	2K
A	2000	pop	20M
B	1999	cases	37K
B	1999	pop	172M
B	2000	cases	80K
B	2000	pop	174M
C	1999	cases	212K
C	1999	pop	1T
C	2000	cases	213K
C	2000	pop	1T



country	year	cases	pop
A	1999	0.7K	19M
A	2000	2K	20M
B	1999	37K	172M
B	2000	80K	174M
C	1999	212K	1T
C	2000	213K	1T

`pivot_wider`(data, names_from = "name", values_from = "value")

The inverse of `pivot_longer()`. "Widen" data by expanding two columns into several. One column provides the new column names, the other the values.

```
pivot_wider(table2, names_from = type,  
            values_from = count)
```

Data tidying with tidyr :: CHEATSHEET

Tidy data is a way to organize tabular data in a consistent data structure across packages. A table is tidy if:



Each **variable** is in its own **column**

&



Each **observation**, or **case**, is in its own **row**



Access **variables** as **vectors**



Preserve **cases** in vectorized operations

Tibbles

AN ENHANCED DATA FRAME

Tibbles are a table format provided by the **tibble** package. They inherit the data frame class, but have improved behaviors:

- **Subset** a new tibble with `[]`, a vector with `[[` and `$`.
- **No partial matching** when subsetting columns.
- **Display** concise views of the data on one screen.

options(tibble.print_max = n, tibble.print_min = m, tibble.width = Inf) Control default display settings.

View() or **glimpse()** View the entire data set.

CONSTRUCT A TIBBLE

tibble(...) Construct by columns.


`tibble(x = 1:3, y = c("a", "b", "c"))`

tibble(...) Construct by rows.

`tribble(~x, ~y,`

1, "a",
2, "b",
3, "c")

Both make this tibble



as_tibble(x, ...) Convert a data frame to a tibble.

enframe(x, name = "name", value = "value")

Convert a named vector to a tibble. Also **deframe()**.

is_tibble(x) Test whether x is a tibble.

Reshape Data

- Pivot data to reorganize values into a new layout.

table4a

country	1999	2000
A	0.7K	2K
B	37K	80K
C	212K	213K

country	year	cases
A	1999	0.7K
B	1999	37K
C	1999	212K
A	2000	2K
B	2000	80K
C	2000	213K

pivot_longer(data, cols, names_to = "name", values_to = "value", values_drop_na = FALSE)

"Lengthen" data by collapsing several columns into two. Column names move to a new names_to column and values to a new values_to column.

`pivot_longer(table4a, cols = 2:3, names_to = "year", values_to = "cases")`

table2

country	year	type	count
A	1999	cases	0.7K
A	1999	pop	19M
A	2000	cases	2K
A	2000	pop	20M
B	1999	cases	37K
B	1999	pop	172M
B	2000	cases	80K
B	2000	pop	174M
C	1999	cases	212K
C	1999	pop	1T
C	2000	cases	213K
C	2000	pop	1T

pivot_wider(data, names_from = "name", values_from = "value")

The inverse of `pivot_longer()`. "Widen" data by expanding two columns into several. One column provides the new column names, the other the values.

`pivot_wider(table2, names_from = type, values_from = count)`

Split Cells

- Use these functions to split or combine cells into individual, isolated values.

table5

country	century	year
A	19	99
A	20	00
B	19	99
B	20	00

country	year
A	1999
A	2000
B	1999
B	2000

unite(data, col, ..., sep = "_", remove = TRUE, na.rm = FALSE) Collapse cells across several columns into a single column.

`unite(table5, century, year, col = "year", sep = "")`

table3

country	year	rate
A	1999	0.7K/19M
A	2000	2K/20M
B	1999	37K/172M
B	2000	80K/174M

country	year	cases	pop
A	1999	0.7K	19M
A	2000	2K	20M
B	1999	37K	172
B	2000	80K	174

separate_wider_delim(data, cols, delim, ..., names = NULL, names_sep = NULL, names_repair = "check unique", too_few, too_many, cols_remove = TRUE) Separate each cell in a column into several columns. Also **separate_wider_regex()** and **separate_wider_position()**.

`separate(table3, rate, sep = "/", into = c("cases", "pop"))`

separate_longer_delim(data, cols, delim, ..., width, keep_empty) Separate each cell in a column into several rows.

`separate_longer_delim(table3, rate, sep = "/")`

Expand Tables

Create new combinations of variables or identify implicit missing values (combinations of variables not present in the data).

x

x1	x2	x3
A	1	3
B	1	4
B	2	3

x1	x2
A	1
A	2
B	1
B	2

expand(data, ...) Create a new tibble with all possible combinations of the values of the variables listed in ... Drop other variables.

`expand(mtcars, cyl, gear, carb)`

x

x1	x2	x3
A	1	3
B	1	4
B	2	3

x1	x2	x3
A	1	3
A	2	NA
B	1	4
B	2	3

complete(data, ..., fill = list()) Add missing possible combinations of values of variables listed in ... Fill remaining variables with NA. `complete(mtcars, cyl, gear, carb)`

Handle Missing Values

Drop or replace explicit missing values (NA).

x

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

x1	x2
A	1
A	2
D	3

drop_na(data, ...) Drop rows containing NA's in ... columns. `drop_na(x, x2)`

x

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

x1	x2
A	1
B	1
C	1
D	3
E	3

fill(data, ..., direction = "down") Fill in NA's in ... columns using the next or previous value. `fill(x, x2)`

x

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

x1	x2
A	1
B	2
C	2
D	3
E	2

replace_na(data, replace) Specify a value to replace NA in selected columns. `replace_na(x, list(x2 = 2))`



Manipulando dados com o dplyr


Manipulando casos

Manipulando variáveis

`arrange()`

`slice()`

`filter()`



Preserve **cases** in
vectorized operations

`summarise()`

`group_by()`


`select()`

`mutate()`

`rename()`


`pull()`

`relocate()`



Access **variables**
as **vectors**

`filter()`



filter(.data, ..., .preserve = FALSE) Extract rows that meet logical criteria.
`mtcars |> filter(mpg > 20)`

`arrange()`



arrange(.data, ..., .by_group = FALSE) Order rows by values of a column or columns (low to high), use with **desc()** to order from high to low.
`mtcars |> arrange(mpg)`
`mtcars |> arrange(desc(mpg))`

`pull()`



pull(.data, var = -1, name = NULL, ...) Extract column values as a vector, by name or index.
`mtcars |> pull(wt)`

`select()`



select(.data, ...) Extract columns as a table.
`mtcars |> select(mpg, wt)`

`relocate()`



relocate(.data, ..., .before = NULL, .after = NULL) Move columns to new position.
`mtcars |> relocate(mpg, cyl, .after = last_col())`

Data transformation with dplyr : : CHEATSHEET



dplyr functions work with pipes and expect **tidy data**. In tidy data:



Each **variable** is in its own **column**

&



Each **observation**, or **case**, is in its own **row**

pipes

x |> **f(y)**
becomes **f(x, y)**

Summarize Cases

Apply **summary functions** to columns to create a new table of summary statistics. Summary functions take vectors as input and return one value (see back).

summary function




summarize(.data, ...)
Compute table of summaries.
mtcars |> summarize(avg = mean(mpg))



count(.data, ..., wt = NULL, sort = FALSE, name = NULL) Count number of rows in each group defined by the variables in ... Also **tally()**, **add_count()**, **add_tally()**.
mtcars |> count(cyl)

Group Cases

Use **group_by(.data, ..., add = FALSE, drop = TRUE)** to create a "grouped" copy of a table grouped by columns in ... **dplyr** functions will manipulate each "group" separately and combine the results.



mtcars |>
group_by(cyl) |>
summarize(avg = mean(mpg))

Alternate grouping syntax with **.by** as an argument:

mtcars |>
summarize(
avg = mean(mpg), .by = cyl)

Use **rowwise(.data, ...)** to group data into individual rows. **dplyr** functions will compute results for each row. Also apply functions to list-columns. See tidy cheat sheet for list-column workflow.



starwars |>
rowwise() |>
mutate(film_count = length(films))

ungroup(x, ...) Returns ungrouped copy of table.
g_mtcars <- mtcars |> group_by(cyl)
ungroup(g_mtcars)

Manipulate Cases

EXTRACT CASES

Row functions return a subset of rows as a new table.




filter(.data, ..., .preserve = FALSE) Extract rows that meet logical criteria.
mtcars |> filter(mpg > 20)




distinct(.data, ..., .keep_all = FALSE) Remove rows with duplicate values.
mtcars |> distinct(gear)



slice(.data, ..., .preserve = FALSE) Select rows by position.
mtcars |> slice(10:15)



slice_sample(.data, ..., n, prop, weight_by = NULL, replace = FALSE) Randomly select rows. Use **n** to select a number of rows and **prop** to select a fraction of rows.
mtcars |> slice_sample(n = 5, replace = TRUE)



slice_min(.data, order_by, ..., n, prop, with_ties = TRUE) and **slice_max()** Select rows with the lowest and highest values.
mtcars |> slice_min(mpg, prop = 0.25)



slice_head(.data, ..., n, prop) and **slice_tail()** Select the first or last rows.
mtcars |> slice_head(n = 5)

Logical and boolean operators to use with filter()

=	<	<=	is.na()	%in%		xor()
!=	>	>=	!is.na()	!	&	


See ?base::Logic and ?Comparison for help.

ARRANGE CASES



arrange(.data, ..., .by_group = FALSE) Order rows by values of a column or columns (low to high), use with **desc()** to order from high to low.
mtcars |> arrange(mpg)
mtcars |> arrange(desc(mpg))

ADD CASES



add_row(.data, ..., .before = NULL, .after = NULL) Add one or more rows to a table.
cars |> add_row(speed = 1, dist = 1)

Manipulate Variables

EXTRACT VARIABLES

Column functions return a set of columns as a new vector or table.



pull(.data, var = -1, name = NULL, ...) Extract column values as a vector, by name or index.
mtcars |> pull(wt)



select(.data, ...) Extract columns as a table.
mtcars |> select(mpg, wt)



relocate(.data, ..., .before = NULL, .after = NULL) Move columns to new position.
mtcars |> relocate(mpg, cyl, .after = last_col())

Use these helpers with select() and across()

e.g. mtcars |> select(mpg:cyl)

contains(match)	num_range(prefix, range)	: e.g., mpg:cyl
ends_with(match)	all_of(x)/any_of(x, ..., vars)	!, e.g., !gear
starts_with(match)	matches(match)	everything()

MANIPULATE MULTIPLE VARIABLES AT ONCE

df <- tibble(x_1 = c(1, 2), x_2 = c(3, 4), y = c(4, 5))



across(.cols, .funs, ..., .names = NULL) Summarize or mutate multiple columns in the same way.
df |> summarize(across(everything(), mean))



c_across(.cols) Compute across columns in row-wise data.
df |>
rowwise() |>
mutate(x_total = sum(c_across(1:2)))

MAKE NEW VARIABLES

Apply **vectorized functions** to columns. Vectorized functions take vectors as input and return vectors of the same length as output (see back).



mutate(.data, ..., .keep = "all", .before = NULL, .after = NULL) Compute new column(s). Also **add_column()**.
mtcars |> mutate(gpm = 1 / mpg)
mtcars |> mutate(gpm = 1 / mpg, .keep = "none")




rename(.data, ...) Rename columns. Use **rename_with()** to rename with a function.
mtcars |> rename(miles_per_gallon = mpg)

Pipes

%>%

|>

```
flights <- flights
head(flights)
## # A tibble: 6 × 19
##   year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>   <int>         <int>         <dbl>   <int>         <int>
## 1  2013     1     1     517             515           2     830             819
## 2  2013     1     1     533             529           4     850             830
## 3  2013     1     1     542             540           2     923             850
## 4  2013     1     1     544             545          -1    1004            1022
## 5  2013     1     1     554             600          -6     812             837
## 6  2013     1     1     554             558          -4     740             728
## #   11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dtm>
#Usando pipe para transformar
```



```
flights |>
  filter(
    !is.na(arr_delay),
    !is.na(tailnum))
|>
  count(dest)
```


```
## # A tibble: 104 × 2
##   dest      n
##   <chr> <int>
## 1 ABQ     254
## 2 ACK     264
## 3 ALB     418
## 4 ANC        8
## 5 ATL    16837
## 6 AUS     2411
## 7 AVL     261
## 8 BDL     412
## 9 BGR     358
## 10 BHM     269
## #   94 more rows
```


Gramática dos Gráficos: ggplot2

Camadas



Gráfico



Y & X



```
1 ggplot(data = <DATA>) +  
2   <GEOM_FUNCTION>(  
3     mapping = aes(<MAPPINGS>),  
4     stat = <STAT>,  
5     position = <POSITION>  
6   ) +  
7   <COORDINATE_FUNCTION> +  
8   <FACET_FUNCTION> +  
9   <SCALE_FUNCTION> +  
10  <THEME_FUNCTION>
```

Personalização e refinamento de Gráficos

Alteração de eixos, títulos e legendas

`labs()`

`xlab()`

`scale_y_continuous()`

`ylab()`

`scale_x_continuous()`

Aplicação de temas e cores

`fill()`

`theme()`

`scale_fill_*`


`scale_color_*`

Criação de múltiplos painéis/gráficos juntos “

`facet_grid()`


`facet_wrap()`

Gráfico de dispersão




`geom_point()`

Gráfico de dispersão




`geom_line()`

Dumbbell plot



`geom_dumbbell()`


Boxplot



`geom_boxplot()`

`geom_violin()`


Ordenação



`geom_point()`

`geom_line()`

Histograma




`geom_col()` `geom_bar()`


`geom_density()`

`geom_histogram()`


Alluvial Diagram




Sankey Diagram




Line Graph



Donut Chart



Bar Chart (Vertical)




Exploded View Drawing



Polar Area Chart




Radial Bar Chart




Sunburst Diagram



Pictorial Percentage Chart



Heat Map



Treemap



Stacked Bar Chart



Radial Histogram



Flow Map



Rótulos

- A principal função é `labs()`, que fica fora do `aes()` permite dar os títulos dos axis, do mapa e tudo.
 - Para os eixos x e y, `xlab()` e `ylab()`
 - `label_wrap_gen()` - permite definir tamanho da coluna para legendas muito longas
 -
- É possível salvar o código da função que gera o plot a um objeto, e utilizar seguido de `<+>` e qualquer função dessas que utilizam `+`. As funções daqui pra frente também podem (e devem) ser usadas assim

Aesthetics arguments

Cor

`color`: cor das linhas `fill`: cor do preenchimento `alpha`: definir transparência entre 0 e 1;

Escala

- `scale_`: muda diferentes escalas (alpha, color, size, shape, radius, x, y, time, fill, hue... etc)

Temas

- A função `theme()` permite customizar as partes não associadas aos dados do plot, como títulos, legendas, fontes, fundos, linhas de gride, legendas.
- Alguns argumentos de `theme`:
 - `line`
 - `rect`
 - `text`
 - `title`
 - `aspect.ratio`
- As funções possuem hierarquias, podendo ser controladas bem especificamente. Usar `?theme()` para saber mais.

Análises multivariadas

- i) reduzir a dimensionalidade dos dados e encontrar a principal direção de variação dos mesmos;
- ii) testar relações entre matrizes, ou ainda;
- iii) encontrar diferenças entre grupos

Análises multivariadas

**Análises de
agrupamento**

Observações
agrupadas por
semelhança

**Análises de
ordenação**

Ordenam
observações
reduzindo a
dimensionalidade

Obrigado!

jpmachado.r@gmail.com